

Speaker script

What a low-cost smartphone protocol can and cannot establish about urban noise

48 slides · 44 spoken, 4 backup · target 28 minutes · Laurian Jamin & Lucas Zborowski

How to use this. The **left column is what you say**, written to be spoken: short sentences, ordinary words, nothing you would have to practise. The **right column is the same thing in French**, so that nobody recites a sentence they do not own. Read the French first, speak the English.

Comment s'en servir. La **colonne de gauche est ce que vous dites**, écrite pour être prononcée : phrases courtes, mots ordinaires, rien qui demande de s'entraîner. La **colonne de droite dit la même chose en français**, pour que personne ne récite une phrase qu'il ne possède pas. Lisez le français d'abord, dites l'anglais.

Four rules that hold for the whole talk

Lead with the negatives	Three of the four results are negative, and that is the contribution. Do not save them for the end.
Never say “measured in dB”	Say <i>relative</i> , or <i>contrast</i> . Nothing here is calibrated against a standard, and one careless sentence undoes twenty minutes of care.
No compliance claim	The QCVN colours are a reading aid. If you say “exceeds the limit”, you have made a regulatory claim this work cannot support.
If you do not know, say so	“We did not test that” is a complete answer and it is the strongest one available to this project.

Timings are cumulative minute marks, not durations. If you are behind at slide 30, cut slides 32 and 33 — they are engineering detail and nothing later depends on them.

Act I — what we set out to do, and what constrains it

slides 1–13 · 0–10 min

1 Title

0:00

Good morning. Our subject is what a smartphone protocol can, and cannot, establish about urban noise.

I want to be clear about one thing before anything else. **This is not a noise map of Hanoi.** We cannot produce one. It is a study of what this method actually supports.

Three months, 363 measurements, three ordinary phones. And three negative results that hold up better than the positive one.

Do not apologise for the negatives here or anywhere. They are the result.

Bonjour. Notre sujet, c'est ce qu'un protocole smartphone peut établir — et ne peut pas établir — sur le bruit urbain. Une chose à poser d'emblée. **Ce n'est pas une carte de bruit de Hanoï.** Nous sommes incapables d'en produire une. C'est une étude de ce que cette méthode supporte réellement.

Trois mois, 363 mesures, trois téléphones ordinaires. Et trois résultats négatifs qui tiennent mieux que le positif.

2 Outline

0:45

Three parts. What we measured and what it supports. Then what our own audit found inside it. Then where it goes — an Android application, and a second city.

The audit is the part you may not expect. It is us auditing ourselves, not a reviewer auditing us.

Trois parties. Ce que nous avons mesuré et ce que ça supporte. Puis ce que notre propre audit y a trouvé. Puis la suite — une application Android, et une deuxième ville. L'audit est la partie inattendue. C'est nous qui nous auditons, pas un relecteur qui nous audite.

4 The gap this project sits in

1:15

Hanoi is dense, growing fast, and its traffic is motorcycles rather than cars.

Vietnam has no national noise-mapping programme. And there is exactly one instrumented campaign ever published for Hanoi. It measured in 2005 to 2007.

Class 1 sound level meters and commercial propagation software are out of reach for most local research budgets. So the question is: how far does a protocol built from three consumer phones and open data actually get you?

Hanoï est dense, en croissance rapide, et son trafic est fait de deux-roues, pas de voitures.

Le Vietnam n'a pas de programme national de cartographie du bruit. Et il existe exactement une campagne instrumentée publiée pour Hanoï. Elle mesurait en 2005–2007.

Les sonomètres de classe 1 et les logiciels de propagation commerciaux sont hors de portée de la plupart des budgets locaux. D'où la question : jusqu'où va vraiment un protocole fait de trois téléphones grand public et de données ouvertes ?

The 2005–2007 campaign is not rhetoric: it is the only anchor we have for absolute levels, and its age is why our bias interval is so wide.

5 Research questions, and what is out of scope

2:00

Four questions, fixed before we ran anything. Can open-data morphology predict noise at an unmeasured place? Does a model transfer between cities? Does traffic flow from video explain the levels? And what can you claim with no absolute reference?

I will give you the answers now. Weakly. No. No. And contrasts, never levels.

Three of the four are negative. An academic audience listens better to *how* once it already knows *what*.

Quatre questions, fixées avant toute analyse. La morphologie issue de données ouvertes prédit-elle le bruit en un point non mesuré ? Un modèle se transfère-t-il d'une ville à l'autre ? Le flux de véhicules extrait de la vidéo explique-t-il les niveaux ? Et que peut-on affirmer sans référence absolue ?

Je donne les réponses tout de suite. Faiblement. Non. Non. Et des contrastes, jamais des niveaux.

Trois réponses sur quatre sont négatives. Un public académique écoute mieux le *comment* quand il connaît déjà le *quoi*.

6 Related work

2:45

The bibliography is organised by what each reference is *for*, not by date.

One paper deserves a sentence. Roberts and colleagues, 2017. Spatial cross-validation must exclude the area your features are built from. That is the paper that made us withdraw our own headline number. It comes back in part two.

La bibliographie est organisée par la *fonction* de chaque référence, pas par date.

Un article mérite une phrase. Roberts et collègues, 2017. La validation croisée spatiale doit exclure la zone d'où viennent vos variables. C'est l'article qui nous a fait retirer notre propre chiffre principal. Il revient en partie deux.

8 The campaign

3:20

363 points across three deliberately contrasted areas. A new peri-urban development, the dense historic quarter, and a transport corridor.

Left: the level distribution per site. Right: the hourly profile. **Those two contrasts are what this protocol supports.** Not the absolute height of either curve — the shape.

Three collectors, three phones, twenty-five seconds per point, an audio clip, a ten-metre GPS gate. Both datasets are published under CC-BY.

363 points sur trois zones délibérément contrastées. Un développement péri-urbain neuf, le quartier historique dense, et un corridor de transport.

À gauche : la distribution des niveaux par site. À droite : le profil horaire. **Ces deux contrastes sont ce que le protocole supporte.** Pas la hauteur absolue des courbes — leur forme.

Trois collecteurs, trois téléphones, vingt-cinq secondes par point, un extrait audio, une porte GPS à dix mètres. Les deux jeux de données sont publiés en CC-BY.

9 Metrology — the spine of the talk

4:15

This slide is the spine of everything that follows.

The three phones were calibrated against *each other*. Never against a reference instrument. **A bias common to all three is invisible in our data by construction.** It cannot be detected from the inside.

So: no absolute level as a fact, and no compliance claim. But contrasts between places and between hours survive, because a common bias cancels in a difference.

And the quantity is written there. A twenty-five second integral. It is not L_{den} , which is a year. Comparing them is not a rounding error, it is a category error.

Cette diapo est la colonne vertébrale de tout ce qui suit.

Les trois téléphones ont été calibrés *les uns sur les autres*. Jamais contre un instrument de référence. **Un biais commun aux trois est invisible dans nos données par construction.** Indétectable de l'intérieur.

Donc : aucun niveau absolu comme un fait, et aucune revendication de conformité. Mais les contrastes entre lieux et entre heures survivent, parce qu'un biais commun s'annule dans une différence.

Et la grandeur est écrite là. Une intégrale sur vingt-cinq secondes. Ce n'est pas L_{den} , qui est une année. Les comparer n'est pas une erreur d'arrondi, c'est une erreur de catégorie.

Expect this question — and it is a fair one

“Was a single side-by-side reading against a class 2 meter really out of reach?” Answer it, do not deflect: **no, and it is the cheapest thing we could have done.** A half-day rental would settle the absolute scale. It was not done, and it is still not booked. Slide 41 says so on the record. — « Une seule mesure côte à côte avec un sonomètre de classe 2 était-elle vraiment hors de portée ? » Répondez, n'esquivez pas : **non, et c'est la chose la moins chère que nous aurions pu faire.**

11 The chain, end to end

5:30

Left to right, once. Three sources: the survey, OpenStreetMap, the traffic videos. Then cleaning, features, counting. Then evaluation. Then the outputs.

The line to remember is the last one. **The delivered model is chosen by code, not by us.** Script 04 writes which model won; script 07 reads that flag. Nothing downstream can quietly substitute a different one.

This came straight out of the audit. Before it, a permissive split could put a model on the published map that lost every strict split, and nobody would have noticed.

De gauche à droite, une fois. Trois sources : l'enquête, OpenStreetMap, les vidéos de trafic. Puis nettoyage, variables, comptage. Puis évaluation. Puis les sorties.

La ligne à retenir est la dernière. **Le modèle livré est choisi par le code, pas par nous.** Le script 04 écrit quel modèle a gagné ; le script 07 lit ce drapeau. Rien en aval ne peut en substituer un autre discrètement.

12 The evaluation protocol

6:15

If you take one methodological slide away, take this one. Every model is scored under three splits, on identical folds. A permissive one. The reference one — buffered leave-one-out at three hundred metres. And the strictest, leave-one-site-out.

Why three hundred metres? **Because the features aggregate over a disc of radius three hundred metres.** Two points a hundred metres apart share more than eighty-five percent of that disc. Group them together and the model is being tested on near-twins of its own training data. That score is not out-of-sample.

The buffer must equal the feature radius. That is the rule. It is also the rule we broke, in July.

Si vous ne retenez qu'une diapo de méthode, retenez celle-ci.

Chaque modèle est évalué sous trois découpages, sur des plis identiques. Un permissif. Le découpage de référence — leave-one-out tamponné à trois cents mètres. Et le plus strict, leave-one-site-out.

Pourquoi trois cents mètres ? **Parce que les variables agrègent sur un disque de rayon trois cents mètres.** Deux points distants de cent mètres partagent plus de quatre-vingt-cinq pour cent de ce disque. Regroupez-les et le modèle est testé sur des quasi-jumeaux de son entraînement. Ce score n'est pas hors-échantillon.

Le tampon doit égaler le rayon des variables. C'est la règle. C'est aussi la règle que nous avons enfreinte, en juillet.

13 Eight models, three baselines, one ablation

7:30

Nothing is compared against nothing. The baselines are the point.

Two things worth saying out loud. First, mean-per-site-per-hour is a hard baseline, and we said so before running it — a lookup table is genuinely informative in a city with this traffic rhythm.

Second, the hybrid — physics plus machine learning — is **the architecture we ourselves had recommended** in an earlier draft. We put it in the list and let it lose. That is the whole point of the next section.

Rien n'est comparé à rien. Les baselines sont l'essentiel.

Deux choses à dire à voix haute. D'abord, la moyenne par site et par heure est une baseline exigeante, et nous l'avons dit avant de la lancer — une table de correspondance est réellement informative dans une ville à ce rythme de trafic.

Ensuite, l'hybride — physique plus apprentissage — c'est **l'architecture que nous avions nous-mêmes recommandée** dans une version antérieure. Nous l'avons mise dans la liste et laissée perdre. C'est tout l'enjeu de la section suivante.

Act II — the results, and the audit of our own work

slides 14–26 · 8–16 min

15 The ranking inverts

8:15

Give the room fifteen seconds on this before you speak. It lands much harder found than told.

Read across, not down. On the permissive split, the elaborate hybrid wins — it is the top line on the left. On the two strict splits it collapses. The green line, three parameters, barely moves.

The ranking reverses between a permissive split and one that tests generalisation. That is the result. Not which model won — the fact that the answer depends on the split.

And we reported that the architecture we had recommended loses. It is tested and rejected at this sample size, not deferred to future work.

Laissez la salle quinze secondes avant de parler. Ça marque bien plus quand on le trouve que quand on l'entend.

Lisez en travers, pas de haut en bas. Sur le découpage permissif, l'hybride sophistiqué gagne — c'est la ligne du haut à gauche. Sur les deux découpages stricts, il s'effondre. La ligne verte, trois paramètres, bouge à peine.

Le classement s'inverse entre un découpage permissif et un découpage qui teste la généralisation. C'est ça, le résultat. Pas quel modèle gagne — le fait que la réponse dépende du découpage.

Et nous avons publié que l'architecture que nous recommandions perd. Testée et rejetée à cette taille d'échantillon, pas repoussée aux travaux futurs.

If asked why the hybrid wins the permissive split

Six-hundred-metre blocks still leave near-neighbours in training when the features span three hundred metres. A flexible learner picks up local structure it cannot generalise. That is exactly the effect Roberts 2017 describes. — Des blocs de 600 m laissent encore des voisins proches dans l'entraînement quand les variables portent sur 300 m.

16 The delivered model

9:30

What won is a line-source attenuation law. Two distances, three constants, and **no morphological data at all.**

Note the form. Energy falls as one over d , not one over d squared. A street is a *line* of sources, not a point — so minus three decibels per doubling of distance, not minus six.

One honesty note. The background term fits to minus ninety-nine decibels. That is a boundary solution. **The background is not identifiable from this data**, so what we call a three-parameter model is really two.

And say the error out loud. **A typical prediction is wrong by five decibels.** That is a factor of three in acoustic energy. Enough for a contrast. Nowhere near enough for an assessment.

Ce qui gagne est une loi d'atténuation de source linéique. Deux distances, trois constantes, et **aucune donnée morphologique.**

Notez la forme. L'énergie décroît en un sur d , pas un sur d carré. Une rue est une *ligne* de sources, pas un point — donc moins trois décibels par doublement de distance, pas moins six.

Une note d'honnêteté. Le terme de fond converge vers moins quatre-vingt-dix-neuf décibels. C'est une solution de bord. **Le fond n'est pas identifiable avec ces données**, donc notre modèle à trois paramètres en a réellement deux.

Et dites l'erreur à voix haute. **Une prédiction typique se trompe de cinq décibels.** Un facteur trois en énergie acoustique. Assez pour un contraste. Très loin d'être assez pour une évaluation.

17 “R-squared 0.25 — isn't that very low?”

10:45

This question always comes. It is much stronger answered before it is asked.

Two measurements a few metres apart, at the same hour, must be predicted identically by any spatial model. So whatever they disagree by is variance **no spatial model can ever explain**.

Twenty-nine such pairs under twenty metres. They differ by four point two decibels on average. Work that through and, at the forty-metre scale the map works at, **the ceiling is around 0.54**.

The delivered model reaches 0.246. **About half of what is attainable, not a tenth of it.**

The caveat is on the slide and I will say it: pairs at the same hour may be on different days, so this includes day-to-day variation and overestimates measurement noise. And twenty-nine pairs is few. It is an order of magnitude, not a bound.

The deeper reason is the quantity itself: a 25-second sample in motorcycle traffic, where a single horn reaches plus seventeen decibels.

Cette question vient toujours. Elle est bien plus forte répondue avant d'être posée.

Deux mesures à quelques mètres l'une de l'autre, à la même heure, doivent être prédites identiquement par tout modèle spatial. Donc leur désaccord est une variance **qu'aucun modèle spatial ne pourra jamais expliquer**.

Vingt-neuf paires de ce type sous vingt mètres. Elles diffèrent de quatre virgule deux décibels en moyenne. En déroulant le calcul, à l'échelle de quarante mètres où travaille la carte, **le plafond est autour de 0,54**.

Le modèle livré atteint 0,246. **Environ la moitié de l'atteignable, pas le dixième.**

La réserve est sur la diapo et je la dis : des paires à la même heure peuvent être sur des jours différents, donc ceci inclut la variation jour à jour et surestime le bruit de mesure. Et vingt-neuf paires, c'est peu. C'est un ordre de grandeur, pas une borne.

18 The map, and the caveat

12:00

The predicted grid over the three measured areas. Forty-metre cells.

Two caveats, and I want to be first to say both.

The grid step is not the accuracy. Forty-metre cells drawn from a model whose typical error is five decibels promise a precision they do not have. Those are routinely confused — including by us, in July.

And **there is no hour**. The export carries seventeen hourly columns and all seventeen are identical, for every cell. The kernel has no hour term. The application removed its hour slider for exactly that reason. **Nothing varies that the model does not model.**

The colours are QCVN reference bands, used descriptively. **They are not a compliance statement.**

La grille prédite sur les trois zones mesurées. Cellules de quarante mètres.

Deux réserves, et je veux être le premier à les dire.

Le pas de la grille n'est pas la précision. Des cellules de quarante mètres issues d'un modèle dont l'erreur typique est de cinq décibels promettent une précision qu'elles n'ont pas. On les confond couramment — nous compris, en juillet.

Et **il n'y a pas d'heure**. L'export porte dix-sept colonnes horaires et les dix-sept sont identiques, pour chaque cellule. Le noyau n'a pas de terme horaire. L'application a retiré son curseur d'heure pour exactement cette raison. **Rien ne varie que le modèle ne modélise pas.**

Les couleurs sont les bandes QCVN, en lecture descriptive. **Ce n'est pas une déclaration de conformité.**

19 What the learned model was leaning on

13:00

Two thirds of the learned model's split gain goes to morphology. Built area, road density, distance to the two road classes.

And it buys nothing. Morphology alone scores 0.041 under the reference protocol.

Where a model spends its capacity and where it earns its score are different questions. Only the second one is a result. Feature importance is the most over-read plot in applied machine learning, and this is why.

Deux tiers du gain de séparation du modèle appris vont à la morphologie. Surface bâtie, densité de voirie, distance aux deux classes de routes.

Et ça n'achète rien. La morphologie seule obtient 0,041 sous le protocole de référence.

Où un modèle dépense sa capacité et où il gagne son score sont deux questions différentes. Seule la seconde est un résultat. L'importance des variables est le graphique le plus sur-interprété du machine learning appliqué, et voilà pourquoi.

20 The three negative results

13:45

These three are the contribution. Say it in those words.

One. At 363 points over three sites, three physical parameters beat every learned model we built. Capacity does not pay.

Two, and this is the one with the most reuse value. Cross-city transfer fails — and in three distinct ways. It is not a calibration offset: remove the twenty-six-decibel mean difference and R-squared is still negative. Version one transfers **anti-information** — its correlation with Hanoi is *negative*, it ranks quiet and loud the wrong way round. Version two, with convention-invariant features, leaves nothing: correlation plus zero point zero eight. **Not wrong. Empty.**

Against which, log distance to road alone, fitted locally, reaches 0.240. **One local distance term carries more than a sixty-one-thousand-point model from another city carries at all.**

Three. Vehicle flow from video does not explain the levels. And I am not going to let that stand as a clean physical finding, because our own audit says it is not.

Ces trois-là sont la contribution. Dites-le avec ces mots.

Un. À 363 points sur trois sites, trois paramètres physiques battent tous les modèles appris. La capacité ne paie pas.

Deux, et c'est celui qui a le plus de valeur de réutilisation. Le transfert entre villes échoue — et de trois façons distinctes. Ce n'est pas un décalage de calibration : retirez les vingt-six décibels d'écart moyen et le R^2 reste négatif. La version un transfère de **l'anti-information** — sa corrélation avec Hanoï est *négative*, elle classe le calme et le bruyant à l'envers. La version deux, à variables invariantes de convention, ne laisse rien : corrélation plus zéro virgule zéro huit. **Pas fausse. Vide.**

Face à quoi, le log de la distance à la route seul, ajusté localement, atteint 0,240. **Un seul terme de distance local porte plus qu'un modèle de soixante-et-un mille points d'une autre ville n'en porte du tout.**

Trois. Le flux de véhicules issu de la vidéo n'explique pas les niveaux. Et je ne vais pas laisser ça passer pour un résultat physique propre, parce que notre propre audit dit le contraire.

22 We found one of our own results was wrong

15:00

In August we withdrew our own headline number.

A model scored R-squared equals 0.45 under what we then described as honest spatial cross-validation. A simulation was built on it. A project update presented it.

The grouping was on hundred-and-ten-metre cells while the features aggregate over three hundred. **It leaked.**

What replaced it is 0.246 — roughly half. The retracted deck and map are in the archive **with their reason attached**, not deleted. Nine corrections were applied the same day. And the project pivoted, from producing a noise map to studying what this protocol supports.

En août nous avons retiré notre propre chiffre principal.

Un modèle obtenait un R^2 de 0,45 sous ce que nous décrivions alors comme une validation croisée spatiale honnête. Une simulation avait été construite dessus. Une présentation d'avancement l'avait montré.

Le regroupement se faisait sur des cellules de cent dix mètres alors que les variables agrègent sur trois cents. **Il y avait fuite.**

Ce qui l'a remplacé, c'est 0,246 — à peu près la moitié. La présentation et la carte retirées sont dans l'archive **avec leur raison**, pas supprimées. Neuf corrections appliquées le jour même. Et le projet a pivoté, de produire une carte de bruit vers étudier ce que ce protocole supporte.

Lead the whole talk with this slide if the supervisor is in the room. It is the strongest evidence that the other numbers can be trusted.

23 A second audit, on the data itself

16:00

The first audit checked the method. This one checks the measurements.

The top half matters as much as the bottom. Raw rows against published rows: three hundred and sixty-three to three hundred and sixty-three, nothing dropped. Every figure in the README matches the metrics file exactly. No duplicates, weather consistent, tests passing.

That is what makes the bottom half credible rather than alarming. Three findings. None of them was known when the results section was written.

Le premier audit vérifiait la méthode. Celui-ci vérifie les mesures.

La moitié haute compte autant que la basse. Lignes brutes contre lignes publiées : trois cent soixante-trois à trois cent soixante-trois, rien de perdu. Chaque chiffre du README correspond exactement au fichier de métriques. Pas de doublons, météo cohérente, tests au vert.

C'est ça qui rend la moitié basse crédible plutôt qu'alarmante. Trois constats. Aucun n'était connu quand la section résultats a été écrite.

24 Finding 1 — a five-decibel discontinuity

16:45

On the twenty-seventh of June the level distribution steps down by five decibels, and it is not an artefact of when we sampled — it survives controlling for site, hour and noise class.

Be precise about what this does and does not establish. **It does not show the R-squared is inflated.** It shows there is a large, undocumented, spatially structured discontinuity that the model has no term for, and that nobody has tested.

Spatially structured is the worrying part. A classifier predicts before-or-after from latitude and longitude alone, at an AUC of 0.83. So if the shift is instrumental, **a model can learn it as morphology.**

Status: open. The test is specified and has not been run. If you ask me which cause — we do not know. The form version changed that day. Saying more than that would be inventing.

Le vingt-sept juin, la distribution des niveaux descend d'une marche de cinq décibels, et ce n'est pas un artefact d'échantillonnage — ça survit au contrôle par site, heure et classe de bruit.

Soyez précis sur ce que ça établit et ce que ça n'établit pas. **Ça ne montre pas que le R² est gonflé.** Ça montre qu'il existe une discontinuité large, non documentée, spatialement structurée, que le modèle n'a aucun terme pour représenter, et que personne n'a testée.

Spatialement structurée, c'est la partie inquiétante. Un classifieur prédit avant-ou-après à partir de la seule latitude-longitude, avec une AUC de 0,83. Donc si la marche est instrumentale, **un modèle peut l'apprendre comme de la morphologie.**

Statut : ouvert. Le test est spécifié et n'a pas été lancé. Si vous me demandez la cause — nous ne savons pas. La version du formulaire a changé ce jour-là. En dire plus serait inventer.

25 Findings 2 and 3

17:45

The video chain is measuring something, but not what we thought. The detector reports fifty-seven percent cars and thirty-six percent motorcycles. In Hanoi. Reality is roughly the inverse.

And the video-to-measurement gaps reach a hundred and sixty-one seconds, for a twenty-five-second sample.

So negative result three is far more likely an **instrument failure** than a finding about acoustics. It should be reported as "the chain could not be made to work". **That is a stronger and more useful statement than the one we started with.**

Finding three is a presentation problem, not a science one. The headline ranking is not statistically separated — the confidence intervals overlap almost entirely. They were always in the metrics file. They were just not carried into the summary table.

La chaîne vidéo mesure quelque chose, mais pas ce que nous pensions. Le détecteur annonce cinquante-sept pour cent de voitures et trente-six pour cent de deux-roues. À Hanoï. La réalité est à peu près l'inverse.

Et les écarts entre vidéo et mesure atteignent cent soixante-et-une secondes, pour un échantillon de vingt-cinq secondes.

Donc le résultat négatif trois est bien plus vraisemblablement un **échec instrumental** qu'un constat sur l'acoustique. Il doit être rapporté comme « la chaîne n'a pas pu être faite fonctionner ». **C'est un énoncé plus fort et plus utile que celui de départ.**

Le constat trois est un problème de présentation, pas de science. Le classement principal n'est pas séparé statistiquement — les intervalles se recouvrent presque entièrement. Ils étaient depuis toujours dans le fichier de métriques. Simplement pas reportés dans le tableau de synthèse.

26 What the audit leaves standing

18:30

The protocol holds. The ranking inversion holds. Negative results one and two hold. Provenance is lossless and checkable.

What needs work before submission: diagnose the June discontinuity, reframe result three as an instrument failure, and carry the intervals everywhere.

And here is the hinge of the talk. **Everything the audit could not repair comes back to one thing: we did not control the instrument.** Not the microphone, not the app that read it, not the form that recorded it, not the clock that timestamped the videos.

That is the argument for the next section.

Le protocole tient. L'inversion du classement tient. Les résultats négatifs un et deux tiennent. La provenance est sans perte et vérifiable.

Ce qui reste à faire avant soumission : diagnostiquer la discontinuité de juin, requalifier le résultat trois en échec instrumental, et propager les intervalles partout.

Et voici la charnière de l'exposé. **Tout ce que l'audit n'a pas pu réparer revient à une seule chose : nous ne contrôlions pas l'instrument.** Ni le microphone, ni l'application qui le lisait, ni le formulaire qui enregistrerait, ni l'horloge qui horodatait les vidéos.

C'est l'argument de la section suivante.

Act III — from a pipeline to an instrument

slides 27–36 · 19–25 min

28 Three months, in one picture

19:00

Do not read every box. Point at the two raised labels — those are the two retractions — and then at the last one.

The pattern is the story. **Every phase ended by rejecting its own preferred answer.** The transfer we set out to do. Then the R-squared we had presented. Then the architecture we had recommended ourselves.

And each rejection pointed at the same root cause. So the last three weeks were spent building an instrument.

Ne lisez pas chaque case. Pointez les deux étiquettes surélevées — ce sont les deux retraits — puis la dernière.

Le motif est l'histoire. **Chaque phase s'est terminée en rejetant sa propre réponse préférée.** Le transfert que nous voulions faire. Puis le R^2 que nous avons présenté. Puis l'architecture que nous avons nous-mêmes recommandée.

Et chaque rejet pointait la même cause racine. Donc les trois dernières semaines ont servi à construire un instrument.

29 Why build an application at all

20:00

Four things the campaign could not do.

Control the instrument — the app we used is closed, we could not see its weighting or its window. Measure and record in one session — two apps meant the level of one stretch of street and the audio of another. Scale beyond three people. And record what the device even was.

Point two surprises people, and it is a real platform constraint: Android does not normally grant the microphone to two consumers at once. One session now does both.

Quatre choses que la campagne ne pouvait pas faire.

Contrôler l'instrument — l'application utilisée est fermée, on ne voyait ni sa pondération ni sa fenêtre. Mesurer et enregistrer dans une seule session — deux applications, donc le niveau d'un bout de rue et l'audio d'un autre. Passer l'échelle au-delà de trois personnes. Et enregistrer ce qu'était l'appareil.

Le point deux surprend, et c'est une vraie contrainte de plateforme : Android n'accorde normalement pas le microphone à deux consommateurs à la fois. Une seule session fait maintenant les deux.

30 The application

21:00

One sentence each, left to right. Collect — both forms, offline. Measure — twenty-five seconds, A-weighted. Map — the predicted level where you are standing. Results — read from the metrics file, negative results included.

And say this plainly: these are drawings, made from the source code. Not device screenshots. The application has never been run in front of a sound source. That is the honest limitation four slides from now, and presenting a mock-up as a screenshot would contradict everything this talk argues.

Une phrase par écran, de gauche à droite. Collecter — les deux formulaires, hors ligne. Mesurer — vingt-cinq secondes, pondéré A. Carte — le niveau prédit là où vous êtes. Résultats — lus depuis le fichier de métriques, résultats négatifs compris.

Et dites-le franchement : ce sont des dessins, faits depuis le code source. Pas des captures d'écran.

L'application n'a jamais tourné devant une source sonore. C'est la limite honnête de la diapo dans quatre, et présenter une maquette comme une capture contredirait tout ce que cet exposé défend.

31 What was built — phase by phase

22:00

Summarise if you are with a supervisor; go slowly if you are with the people who will inherit it. **This is the slide they should photograph.**

Phases one and two were deliberately not separated, for the microphone reason.

Phase four got simpler on contact with reality: the published grid is already the kernel's output at forty metres, so reading the nearest cell *is* the prediction, exactly and by construction.

Phase six is not built, and I am not going to hide it. Backend, quota, moderation, deduplication.

Résumez si vous êtes face à un encadrant ; ralentissez face à ceux qui vont en hériter. **C'est la diapo qu'ils devraient photographier.**

Les phases un et deux n'ont délibérément pas été séparées, pour la raison du microphone.

La phase quatre s'est simplifiée au contact du réel : la grille publiée est déjà la sortie du noyau à quarante mètres, donc lire la cellule la plus proche *est* la prédiction, exactement et par construction.

La phase six n'est pas construite, et je ne vais pas le cacher. Backend, quotas, modération, déduplication.

32 Architecture, and the one design rule

22:45

One rule matters. **The application does not carry a copy of the study.** The build copies the map, the measurements and the metrics file out of the repository at build time. Re-run the pipeline, rebuild, and the app moves with it. No number is transcribed.

Same principle, third time. The report reads the metrics file. The dashboard reads it. Now the app reads it. **Every published number has exactly one home.**

That rule came out of the first audit — until August the same R-squared appeared in three documents at once, which is three chances to diverge. And they had.

Une règle compte. **L'application ne porte pas une copie de l'étude.** La compilation copie la carte, les mesures et le fichier de métriques depuis le dépôt au moment du build. Relancez le pipeline, recompilez, et l'application suit. Aucun chiffre n'est recopié.

Même principe, troisième fois. Le rapport lit le fichier de métriques. Le tableau de bord le lit. Maintenant l'application le lit. **Chaque chiffre publié a exactement un domicile.**

Cette règle vient du premier audit — jusqu'en août le même R² apparaissait dans trois documents à la fois, soit trois occasions de diverger. Et ils avaient divergé.

33 Three engineering results

23:30

Three things that each cost a day and are invisible in a results table.

GAMA does not run on a phone, so the app reaches it two ways — I will come back to that on the next slide.

The middle one is worth dwelling on. **The same mistake was made twice.** Scaling total energy by a traffic multiplier double-counts the background. We found it and corrected it in Python in July. Then rebuilt it in Kotlin in August, knowing about it. It gave minus seven decibels where the model gives minus three point seven. **Knowing a mistake is not the same as being immune to it.** What caught it the second time was a test asserting an invariant.

And the third: KoboToolbox renames your form on deployment. The first real submission failed with a 404 for a form the server had never heard of. **None of that is visible from the phone** — which is the argument for testing against the real server rather than reasoning about it.

Trois choses qui ont coûté un jour chacune et sont invisibles dans un tableau de résultats.

GAMA ne tourne pas sur un téléphone, donc l'application l'atteint de deux façons — j'y reviens à la diapo suivante.

Celle du milieu mérite qu'on s'y arrête. **La même erreur a été commise deux fois.** Multiplier l'énergie totale par un facteur de trafic compte le fond deux fois. Nous l'avons trouvée et corrigée en Python en juillet. Puis reconstruite en Kotlin en août, en la connaissant. Elle donnait moins sept décibels là où le modèle donne moins trois virgule sept. **Connaître une erreur ne rend pas immunisé contre elle.** Ce qui l'a rattrapée la seconde fois, c'est un test qui affirme un invariant.

Et la troisième : KoboToolbox renomme votre formulaire au déploiement. La première vraie soumission a échoué en 404, pour un formulaire que le serveur n'avait jamais connu. **Rien de tout ça n'est visible depuis le téléphone** — ce qui est l'argument pour tester contre le vrai serveur plutôt que de raisonner dessus.

34 What the app measures, and what it refuses to claim

24:15

The app's level is a *different quantity* from the campaign's. This handset's microphone, not a trimmed reading from one of three cross-calibrated phones. It goes in its own field, with the device and the audio source the platform granted. **The two never share a column.**

Verified end to end against the live server: a fix, a twenty-five second measurement, the instance written, a submission accepted.

And the important one, which is not verified. **The level has never been checked against a sound source.** An emulator records silence. Until a reading from this app is compared to a meter, the absolute figure means nothing at all — which, and I want to be even-handed here, **is equally true of the campaign's own numbers.**

Le niveau de l'application est une *grandeur différente* de celle de la campagne. Le microphone de ce téléphone-ci, pas une lecture ajustée d'un des trois téléphones intercalibrés. Il va dans son propre champ, avec l'appareil et la source audio que la plateforme a accordée. **Les deux ne partagent jamais une colonne.**

Vérifié de bout en bout contre le serveur réel : un point GPS, une mesure de vingt-cinq secondes, l'instance écrite, une soumission acceptée.

Et l'important, qui n'est pas vérifié. **Le niveau n'a jamais été confronté à une source sonore.** Un émulateur enregistre du silence. Tant qu'une lecture de cette application n'est pas comparée à un sonomètre, le chiffre absolu ne veut rien dire — ce qui, et je veux être équitable, **vaut tout autant pour les chiffres de la campagne.**

35 Driving GAMA from the phone

25:00

This is new since the last version of this talk, so let me say how it is wired.

GAMA is an Eclipse desktop platform with no Android port. But it exposes a WebSocket API. You start it headless with a socket, and the application is simply a client: load, play, step, ask, stop. **The phone is a remote control and a screen. It runs nothing.**

Two things only driving it teaches you, and neither is in any documentation. An experiment with a graphical display **kills the socket** when it loads — it takes the main thread. And *step* without *sync* advances nothing, while every indicator reads zero and reports success.

And it does not invent a picture. Every layer and colour is read from the model's own aspect blocks, in declaration order — because in GAMA **declaration order is the stacking**, and reversing it buries the measurements under the buildings.

What this buys is the half of the model a precomputed grid cannot hold: the mitigation scenarios, the construction sites, the fleet by hour. Verified from the phone — sixty-two point nine seven decibels with no mitigation, sixty point five three under pedestrianisation. The same figures the model gives when driven directly.

C'est nouveau depuis la dernière version de cet exposé, alors laissez-moi dire comment c'est branché.

GAMA est une plateforme de bureau Eclipse, sans portage Android. Mais elle expose une API WebSocket. On la lance en mode headless avec un socket, et l'application est simplement un client : load, play, step, ask, stop. **Le téléphone est une télécommande et un écran. Il n'exécute rien.**

Deux choses que seule la pratique enseigne, et aucune n'est documentée. Une expérience avec affichage graphique **tue le socket** au chargement — elle prend le thread principal. Et *step* sans *sync* n'avance rien, pendant que chaque indicateur lit zéro et signale un succès.

Et elle n'invente pas une image. Chaque couche et chaque couleur est lue depuis les blocs *aspect* du modèle, dans l'ordre de déclaration — parce qu'en GAMA **l'ordre de déclaration est l'empilement**, et l'inverser enterre les mesures sous les bâtiments.

Ce que ça apporte, c'est la moitié du modèle qu'une grille précalculée ne peut pas porter : les scénarios de mitigation, les chantiers, la flotte par heure. Vérifié depuis le téléphone — soixante-deux virgule quatre-vingt-dix-sept décibels sans mitigation, soixante virgule cinquante-trois en piétonnisation. Les mêmes chiffres que le modèle donne piloté directement.

36 Before this app goes to strangers

26:00

Three things stop this being handed out, and **none of them is a bug**. The software is finished on its side.

One. Whoever owns the KoboToolbox account holds the positions and timestamps of people they have never met, and answers for them. It must be an institutional account, not a student's — a personal account leaves with its owner. The account is a build flag, never a constant, so **this is a decision, not a code change**. And it is not ours to make.

Two. A consent screen is not an ethics review. A public campaign is a new collection campaign. Our video collection went ahead without review and the repository says so plainly. **We should not repeat that at a larger scale.**

Three. Where does the GAMA server live once it is not a laptop in this room? For a demo it just has to be on and reachable. Beyond that it needs hosting, with TLS — a release build accepts secure sockets only.

Trois choses empêchent de la distribuer, et **aucune n'est un bug**. Le logiciel est fini de son côté.

Un. Celui qui détient le compte KoboToolbox détient les positions et horodatages de gens qu'il n'a jamais rencontrés, et en répond. Ce doit être un compte institutionnel, pas celui d'un étudiant — un compte personnel part avec son propriétaire. Le compte est un drapeau de compilation, jamais une constante, donc **c'est une décision, pas une modification**. Et ce n'est pas à nous de la prendre.

Deux. Un écran de consentement n'est pas un avis éthique. Une campagne publique est une nouvelle campagne de collecte. Notre collecte vidéo s'est faite sans examen et le dépôt le dit clairement. **Ne refaisons pas ça à plus grande échelle.**

Trois. Où vit le serveur GAMA quand ce n'est plus un portable dans cette salle ? Pour une démo, il suffit qu'il soit allumé et joignable. Au-delà, il faut de l'hébergement, avec TLS — une version de release n'accepte que les sockets sécurisés.

Act IV — what comes next, and what we would defend

slides 37–44 · 26–30 min

38 Clermont-Ferrand — what it does and does not change

26:45

I want to correct an expectation before anyone forms it.

There will be no sound level meter at Clermont either.

An earlier version of this talk said institutional equipment would close the calibration gap. It will not. The level stays relative, and the half-day next to a class 2 meter remains *unbooked*, not *done*.

So the honest description of the coming months is: **maintenance and deployment**. Keep the application alive — dependencies, Android target, the form identifiers, the server protocol — then get it collecting in a second city.

That is less glamorous than new physics, and it buys the strongest experiment available to this work. **The same binary in both cities**. The instrument stops being a confound — which is the one thing the Uganda transfer could never fix. And two fabrics as different as we could pick: two-wheelers against cars and a tram, dense organic against European planned, flat delta against volcanic relief. And it finally moves the number that bounded everything here. **Three typologies becomes four or five.**

Je veux corriger une attente avant que quiconque la forme.

Il n'y aura pas non plus de sonomètre à Clermont. Une version antérieure de cet exposé disait que l'équipement institutionnel refermerait l'écart de calibration. Il ne le fera pas. Le niveau reste relatif, et la demi-journée à côté d'un sonomètre de classe 2 reste *non réservée*, pas *faite*.

Donc la description honnête des mois qui viennent, c'est : **maintenance et déploiement**. Garder l'application vivante — dépendances, cible Android, identifiants de formulaires, protocole serveur — puis la faire collecter dans une deuxième ville.

C'est moins spectaculaire que de la nouvelle physique, et ça achète l'expérience la plus forte disponible pour ce travail. **Le même binaire dans les deux villes**. L'instrument cesse d'être un facteur de confusion — la seule chose que le transfert Ouganda ne pouvait pas régler. Et deux tissus urbains aussi différents que possible : deux-roues contre voitures et tramway, dense organique contre européen planifié, delta plat contre relief volcanique.

Et ça déplace enfin le nombre qui bornait tout ici. **Trois typologies deviennent quatre ou cinq.**

If someone asks about calibration again

The half-day rental is still the answer, still cheap, and still not booked. Say that. **Do not imply Clermont solves it.** — La demi-journée de location reste la réponse, reste peu chère, et reste non réservée. Dites-le. **Ne laissez pas entendre que Clermont règle la question.**

39 The comparative deployment

28:00

This is the strongest slide in the section and it is worth the time.

Negative result two says transfer fails. But in that experiment **the instrument, the protocol and the feature conventions all differed too**. So “transfer fails” and “the two datasets are not commensurable” are not separable. It is an over-determined result.

With one application deployed in both cities, the instrument stops being a confound. **A transfer failure then means what it says**. That is a genuine experimental design, not a wish.

And Clermont-Ferrand falls under EU strategic noise mapping. **For the first time, predictions can be compared against an official, instrumented reference map**. Hanoi had no ground truth at all — which is why we ended up anchoring against a campaign from two thousand and five.

C'est la diapo la plus forte de la section et elle mérite du temps.

Le résultat négatif deux dit que le transfert échoue. Mais dans cette expérience, **l'instrument, le protocole et les conventions de variables différaient aussi**. Donc « le transfert échoue » et « les deux jeux ne sont pas commensurables » ne sont pas séparables. C'est un résultat sur-déterminé.

Avec une seule application déployée dans les deux villes, l'instrument cesse d'être un facteur de confusion. **Un échec de transfert veut alors dire ce qu'il dit**. C'est un vrai plan d'expérience, pas un souhait.

Et Clermont-Ferrand relève de la cartographie stratégique européenne du bruit. **Pour la première fois, les prédictions peuvent être comparées à une carte de référence officielle et instrumentée**. Hanoi n'avait aucune vérité terrain — d'où l'ancrage sur une campagne de deux mille cinq.

40 The programme, staged

29:00

Five stages, sequenced by dependency and not by calendar. Every stage has a gate, and **the gates are falsifiable** — a roadmap without exit conditions is a wish list.

Point at the physics gate. It is written so a negative answer is still a result. If a real propagation model does not beat three constants on this data, that is a genuinely interesting finding about how much physics you can use at this sample size, and it gets published either way.

And be honest that stage four depends on things nobody has confirmed. Framing and funding at Clermont are not settled. **Do not present it as scheduled.**

Cinq étapes, séquencées par dépendance et non par calendrier. Chaque étape a une porte, et **les portes sont falsifiables** — une feuille de route sans conditions de sortie est une liste de vœux.

Pointez la porte de la physique. Elle est écrite pour qu'une réponse négative reste un résultat. Si un vrai modèle de propagation ne bat pas trois constantes sur ces données, c'est un constat réellement intéressant sur la quantité de physique utilisable à cette taille d'échantillon, et ça se publie dans les deux cas.

Et soyez honnête : l'étape quatre dépend de choses que personne n'a confirmées. Le cadre et le financement à Clermont ne sont pas réglés. **Ne la présentez pas comme planifiée.**

41 The two things a reviewer will press on

29:45

Two objections, and both are better raised by us than by a reviewer.

First. No absolute reference. Our metrology document owns this squarely — but an acoustics reviewer will not ask whether we *knew*. They will ask whether one side-by-side reading against a class 2 meter was genuinely unobtainable. It is the right question, and the honest answer is that a half-day rental would settle it. **One reading turns “calibrated in relative terms” into “calibrated”.** It is the cheapest item anywhere in this work.

Second, and this is the deeper one. Three sites are three typologies. Our own text says it: the number of independent morphological configurations is close to three, whatever the number of points. Three hundred and sixty-three measurements do not buy three hundred and sixty-three measurements' worth of generalisation.

The hard limit is the design, not the R-squared. Leave-one-site-out is the column that measures it directly, and a fourth and fifth contrasting fabric would do more than any modelling change.

Deux objections, et les deux valent mieux soulevées par nous que par un relecteur.

Première. Pas de référence absolue. Notre document de métrologie l'assume franchement — mais un relecteur en acoustique ne demandera pas si nous *savions*. Il demandera si une seule mesure côte à côte avec un sonomètre de classe 2 était vraiment inatteignable. C'est la bonne question, et la réponse honnête est qu'une demi-journée de location y répondrait. **Une mesure transforme « calibré en relatif » en « calibré ».** C'est l'élément le moins cher de tout ce travail.

Deuxième, et c'est la plus profonde. Trois sites, c'est trois typologies. Notre propre texte le dit : le nombre de configurations morphologiques indépendantes est proche de trois, quel que soit le nombre de points. Trois cent soixante-trois mesures n'achètent pas trois cent soixante-trois mesures de généralisation.

La limite dure, c'est le plan d'échantillonnage, pas le R². Le leave-one-site-out est la colonne qui le mesure directement, et un quatrième et un cinquième tissu contrasté feraient plus que n'importe quel changement de modèle.

43 What this work established

30:30

Four findings, and six practices that make them trustworthy.

If the room is technical, close on the right-hand column. Those six practices transfer to any spatial machine learning project, and they are the part of this work most likely to be reused by someone who never measures a decibel.

The buffer matches the feature radius — always. Baselines and an ablation on the same splits. The delivered model chosen by code. Every number with exactly one home. Retracted work archived with its reason. Nothing predicted outside the sampled envelope.

And the last line is the thesis of the whole talk. **The deliverable is a protocol, an instrument and an honest error bar. Not a noise map of Hanoi.**

Say it slowly.

Quatre constats, et six pratiques qui les rendent fiables.

Si la salle est technique, terminez sur la colonne de droite. Ces six pratiques se transfèrent à n'importe quel projet de machine learning spatial, et c'est la part de ce travail la plus susceptible d'être réutilisée par quelqu'un qui ne mesurera jamais un décibel.

Le tampon égale le rayon des variables — toujours. Baselines et ablation sur les mêmes découpages. Le modèle livré choisi par le code. Chaque chiffre avec exactement un domicile. Le travail retiré archivé avec sa raison. Rien de prédit hors de l'enveloppe échantillonnée.

Et la dernière ligne est la thèse de tout l'exposé. **Le livrable, c'est un protocole, un instrument et une barre d'erreur honnête. Pas une carte de bruit de Hanoi.**

Dites-la lentement.

44 Thank you

31:00

Thank you. Everything on these slides rebuilds from the repository — four make commands, from two published CSV files. No raw export, no six gigabytes of video.

I would rather offer you that than a summary.

Merci. Tout ce qui est sur ces diapos se reconstruit depuis le dépôt — quatre commandes make, à partir de deux fichiers CSV publiés. Pas d'export brut, pas six gigaoctets de vidéo.

Je préfère vous offrir ça qu'un résumé.

The backup slides, and the questions to expect

slides 45–48

Four backup slides exist to be jumped to. Know which one answers what.

If asked	Go to	And say
“What exactly did you measure?” / “Why a distance law?”	45 — every formula	Decibels add in <i>energy</i> , never as levels — every simulation mistake this project made came from forgetting that. And the buffer radius <i>equals</i> the feature radius; the retracted 0.45 came from breaking that identity.
“Is that ranking significant?”	46 — the forest plot	No. <code>physical</code> and <code>dist_road</code> overlap almost entirely. “The physical kernel beats log-distance” is a coin flip at this sample size. Show the plot rather than arguing.
“How wrong could your absolute levels be?”	47 — the bias interval	Plausibly +3.0 to +7.3 dB, from peer-reviewed instrumented campaigns. It is <i>reported and never applied</i> — no offset is written anywhere in the code.
“Can we have the data?”	48 — what is published	Measurements, counts and both forms, CC-BY. Not the videos — faces and plates — and not the raw export. No ethics review was requested for the video collection and none is claimed.

The four answers to have ready, in one place

“It is not calibrated.”

Any question about absolute levels. Never say “measured in dB SPL”.

“We did not test that.”

A complete answer. Stronger than a plausible guess, and this project has spent twenty minutes earning the right to say it.

“That is descriptive, not a compliance claim.”

Any question about the QCVN colours or exceedances.

“It is in the repository, with its reason.”

Anything about the retraction, the archive, or why an artefact still exists.

Trois pièges de langue, en anglais

« We measured 68 dB »

Dites **“we recorded a relative level of 68”**. En anglais comme en français, « measured » sous-entend un instrument étalonné.

« It exceeds the limit »

Dites **“it sits above the QCVN reference band”**. « Limit » est un mot réglementaire.

« The app runs GAMA »

Dites **“the app drives GAMA over a socket and redraws its display”**. Quelqu’un qui connaît la plateforme entendra la différence.